

Máster en Inteligencia Artificial y Big Data

Recomendación de vehículos basado en rutas

Víctor Duart Mouzo

ÍNDICE

Resumen **3**
Problema **3**
Introducción 3
Propuesta de solución 4
Justificación de la solución 4
Objetivo 5
Ejecución de solución **5**
Estado Inicial 5
Exploración de datos 6
Inspección inicial y análisis del dataset 6
Datos de tipo objeto 7
Distribución de datos de tipo objeto 8
Datos de tipo número 9
Distribución de datos de tipo número 9
Limpieza del dataset 10
Valores nulos 10
Duplicados 10
Columnas Price 11
Combustible 12
Km/kg a kmpl 12
Capacidad y potencia del motor 13
Asientos 13
Edad del vehículo 14
Cantidad de propietarios por vehículo 14
Conclusión de la exploración de datos 14
Preprocesamiento de datos 15
Análisis y tratamiento de outliers 15
Machine Learning 16
Modelo de recomendación de vehículos 16
El problema del cold-start 16
Construcción del modelo 16
Conclusión del modelo híbrido 18
Conclusión Final **18**
ANEXOS **19**
Webgrafía 19
Código 21

Resumen

La empresa AlquiloYVendoCoches ha decidido añadir una feature en su página web para que los usuarios puedan alquilar o comprar vehículos filtrando por sus preferencias y utilizando una ruta predefinida o personalizada.

Partimos de datos de unos vehículos procedentes de india el cual hay que hacer una exploración de datos donde prácticamente se modificará una parte del dataset debido a que están pobremente formateado. Una vez hecha la exploración se analizarán y tratarán los datos, se filtrarán los vehículos con las preferencias del usuario para posteriormente con la ruta escogida por el usuario, utilizar un modelo de recomendación basado en conocimiento y contenido. De esta forma se recomendará los vehículos que mejor se adapten a dicha ruta y preferencias del usuario.

Problema

Introducción

AlquiloYVendoCoches es una empresa que alquila y vende vehículos turismo tanto de primera como segunda mano. Utiliza un sistema de recomendación simple y estricto donde los usuarios tienen que rellenar datos muy específicos de los vehículos para conseguir filtrar según sus preferencias. Debido a que este sistema no es fácil de utilizar para aquellos usuarios que no tienen muchos conocimientos sobre vehículos, AlquiloYVendoCoches quiere añadir una segunda opción para poder filtrar los vehículos basándose en ciertas preferencias del usuario y en una ruta seleccionada por el mismo. Esta opción permitirá al usuario tener un filtrado adaptado a su propósito de forma que puede ser útil para usuarios que van a alquilar el vehículo durante un fin de semana para realizar una ruta o, para usuarios que la realizan diariamente y quieren comprar/alquilar el vehículo que mejor se adapte a esa circunstancia.

Propuesta de solución

Para que AlquiloYVendoCoches pueda conseguir que aquellos usuarios que están mucho tiempo mirando vehículos sin comprar/alquilar acaben comprando o alquilando vehículos. Se añadirá una nueva función fácil de usar en la página web para que los usuarios también puedan filtrar por ciertas preferencias y utilizar una ruta predefinida o personalizada. Esta opción permitirá al usuario escoger entre una cantidad de vehículos potenciales para realizar la ruta y que además se adapte a las preferencias del usuario. Esta función filtra los vehículos a partir de las preferencias del usuario, posteriormente se creará un perfil ideal a partir de la ruta, seguidamente se utilizará un sistema de recomendación basado en contenido y conocimiento para poder crear relaciones entre los vehículos y el perfil ideal, para finalmente dar un top de vehículos para que el usuario escoja.

Justificación de la solución

¿Por qué AlquiloYVendoCoches ha decidido añadir esta función?

Después de investigar el mapa de calor de los usuarios en la página web se ha identificado que una gran cantidad se quedan retenidos introduciendo los datos en el apartado de preferencias. Introducen datos que no tienen sentido entre las preferencias o escrolean durante un periodo de tiempo considerable buscando un vehículo que se adapte a sus gustos y preferencias, finalmente sin seleccionar o adquirir ninguno. A causa de esto, AlquiloYVendoCoches aunque está consiguiendo tener una retención de usuarios notable, están perdiendo clientes potenciales que están dispuestos a alquilar/comprar vehículos. Añadir esta nueva funcionalidad permitirá que todo tipo de usuarios pueda filtrar vehículos basándose en ciertas preferencias no técnicas y una ruta de ejemplo. Esto facilitará el filtrado de vehículos y aumentará la posible adquisición de estos.

Objetivo

El objetivo de este proyecto es maximizar los posibles clientes potenciales acelerando y facilitando la fase de selección del vehículo.

Ejecución de solución

Estado Inicial

"Dataset de vehículos" (*Cars Dataset*, 2024b):

Se utiliza un dataset con vehículos procedentes de india. Este dataset contiene información sobre 7252 vehículos, entre ellos:

Id, nombre, ubicación, año, kilómetros recorridos, tipo de combustible, transmisión, cantidad de propietarios del vehículo, kilometraje, capacidad del motor, potencia del vehículo, cantidad de asientos, precio nuevo, precio actual.

	S.No.	Name	Location	Year	Kilometers_Driven	Fuel_T...	Transmission	Owner_Type	Mileage	Engine	Power	Seats	New_Price	Price
0		Maruti Wagon R LXI CNG	Mumbai	2010	72000	CNG	Manual	First	26.6 km/kg	998 CC	58.16 bhp	5.0	*Missing value*	1.75
1		Hyundai Creta 1.6 CRDi SX Option	Pune	2015	41000	Diesel	Manual	First	19.67 kmpl	1582 CC	126.2 bhp	5.0	*Missing value*	12.5
2		Honda Jazz V	Chennai	2011	46000	Petrol	Manual	First	18.2 kmpl	1199 CC	88.7 bhp	5.0	8.61 Lakh	4.5
3		Maruti Ertiga VDI	Chennai	2012	87000	Diesel	Manual	First	20.77 kmpl	1248 CC	88.76 bhp	7.0	*Missing value*	6.0
4		Audi A4 New 2.0 TDI Multitronic	Coimbatore	2013	40670	Diesel	Automatic	Second	15.2 kmpl	1968 CC	140.8 bhp	5.0	*Missing value*	17.74

Dataset de rutas:

El dataset de rutas se ha generado como rutas de ejemplo para utilizar en caso de que el usuario prefiera escoger una ruta predefinida a introducirla.

Este dataset contiene 51 rutas generadas en España y alrededores.Tiene la siguiente información:

Origen, destino, ubicaciones entre origen y destino, distancia en kilómetros, duración en minutos, la media de velocidad, desnivel acumulado, elevación máxima, media de inclinación.

	origin	destination	waypoints	distance_km	duration_min	avg_speed_kph	elevation_gain_m	max_elevation_m	avg_slope
0	Cádiz, Spain	Soria, Spain	*Missing value*	876.493	490.3333333333333	107.25271244051666	2329.4271631240845	1182.90576171875	46.58854326248169
1	Barcelona, Spain	Madrid, Spain	*Missing value*	626.386	382.8666666666667	98.16252829531604	2582.745121955872	1164.331909179688	51.65490243911744
2	Madrid, Spain	Galicia, Spain	*Missing value*	542.968	320.95	101.50515656644338	2314.918029785156	1343.493408203125	46.29836059570312
3	Soria, Spain	Cádiz, Spain	*Missing value*	876.748	495.3333333333333	106.20096904441456	1336.985208511352	1160.195922851562	26.739704170227043
4	Madrid, Spain	Barcelona, Spain	*Missing value*	626.674	378.95	99.22269428684524	1806.5393581390383	1165.033081054688	36.13078716278077

Exploración de datos

Inspección inicial y análisis del dataset

Como bien se ha descrito anteriormente, el dataset de vehículos contiene datos técnicos, de uso y precio sobre turismos. Estos datos probablemente sean procedentes de india debido al Sistema numérico utilizado en la columna "New_Price" como son el "Lakh" y el "Crore"(Cr).

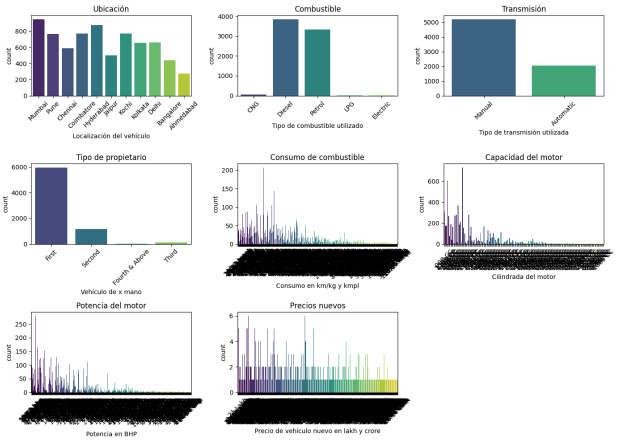
# S.No.	Name	Location	# Year	# Kilometers_Driven	Fuel_T...	Transmission	Owner_Type	Mileage	Engine	Power	# Seats	New_Price	# Price
0	Maruti Wagon R LXI CNG	Mumbai	2010	72000	CNG	Manual	First	26.6 km/kg	998 CC	58.16 bhp	5.0	*Missing value*	1.75
1	Hyundai Creta 1.6 CRDi SX Option	Pune	2015	41000	Diesel	Manual	First	19.67 kmpl	1582 CC	126.2 bhp	5.0	*Missing value*	12.5
2	Honda Jazz V	Chennai	2011	46000	Petrol	Manual	First	18.2 kmpl	1199 CC	88.7 bhp	5.0	8.61 Lakh	4.5
3	Maruti Ertiga VDI	Chennai	2012	87000	Diesel	Manual	First	20.77 kmpl	1248 CC	88.76 bhp	7.0	*Missing value*	6.0
4	Audi A4 New 2.0 TDI Multitronic	Coimbatore	2013	40670	Diesel	Automatic	Second	15.2 kmpl	1968 CC	140.8 bhp	5.0	*Missing value*	17.74

Una vez vistas las cinco primeras filas y los tipos de datos de cada columna se puede llegar a ciertas conclusiones. Hay nueve columnas que son de tipo objeto y cinco que son numéricas. Se puede ver que las columnas ”Mileage”, ”Engine”, ”Power“ y ”New_Price” contienen números y letras en la misma celda. Esto puede ser un gran problema a la hora de procesar los datos ralentizando el proceso. Además, se puede ver que en la columna ”Mileage” hay 2 unidades utilizadas como son el ”kmpl” y el ”km/kg”.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7253 entries, 0 to 7252
Data columns (total 14 columns):
 #   Column             Non-Null Count  Dtype
---  ------             --------------  -----
 0   S.No.              7253 non-null   int64
 1   Name               7253 non-null   object
 2   Location           7253 non-null   object
 3   Year               7253 non-null   int64
 4   Kilometers_Driven  7253 non-null   int64
 5   Fuel_Type          7253 non-null   object
 6   Transmission       7253 non-null   object
 7   Owner_Type         7253 non-null   object
 8   Mileage            7251 non-null   object
 9   Engine             7207 non-null   object
 10  Power              7207 non-null   object
 11  Seats              7200 non-null   float64
 12  New_Price          1006 non-null   object
 13  Price              6019 non-null   float64
dtypes: float64(2), int64(3), object(9)
memory usage: 793.4+ KB
```

A continuación, se visualizarán gráficos donde se puede ver cómo están distribuidos los datos, esto ayudará a entender con qué datos se está trabajando para poder realizar ciertas acciones u otras.

Datos de tipo objeto



Esta gráfica es de tipo countplot, “ayuda a ver la cantidad de ocurrencias de cada categoría en las variables categóricas”. (*Seaborn.Countplot — Seaborn 0.13.2 Documentation*, s. f.-b)

Se puede identificar las siguientes columnas como categóricas puesto que claramente se puede ver las categorías y sus cantidades: “Location”(Ubicación), “Fuel Type”(Combustible),

“Transmission”(Transmisión) y “Owner Type”(Tipo de propietario). Y de estas variables categóricas se puede suponer que;

Ubicación, Combustible y Transmisión son “variables categóricas nominales puesto que sus valores no siguen ningún orden” (Habib, 2024b).

Y Tipo de propietario es una “variable categórica ordinal debido a que sus valores siguen un orden” (Habib, 2024b).

En cuanto a las columnas “Mileage"(Consumo de combustible), “Engine”(Capacidad del motor), “Power”(Potencia del motor) y “New Price”(Precios nuevos), se puede ver la distribución de datos, pero claramente estas columnas no son categóricas. Si se quitan los sufijos se podrían categorizar como variables numéricas, donde;

Capacidad del motor sería una “variable numérica discreta, debido a que se utilizan números enteros conteniendo un número finito de números “(Dubey, 2025).

En cambio, Consumo del combustible, Potencia del motor y Precios nuevos serían “variables numéricas continúas debido a que utilizan números representados con decimales pudiendo contener posibilidades infinitas de números” (Dubey, 2025).

Distribución de datos de tipo objeto

Ubicación: Parece estar balanceado entre todas las ciudades.

Combustible: Está totalmente sesgado hacia “Diesel” y “Petrol”, teniendo la gran mayoría de los datos.

Transmisión: “Manual” contiene la gran mayoría de datos con aproximadamente una ratio de 2:1 sobre “Automatic”.

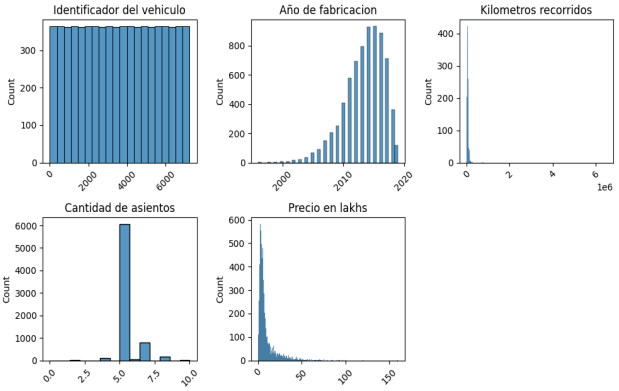
Tipo de propietario: Da a ver que la gran mayoría de los vehículos son de primera mano.

Consumo de combustible, Capacidad del motor y Potencia del motor. Muestran “sesgos hacia el lado derecho” (Chen, 2025b), indicando una gran cantidad de valores bajos.

Precios nuevos: Parece que hay una distribución más equilibrada, pero también da la sensación de que hay menos volumen de datos.

Datos de tipo número

La siguiente gráfica es de tipo histograma, este tipo de "gráfico permite visualizar la distribución de los datos" (*Visualizing Distributions Of Data — Seaborn 0.13.2 Documentation*, s. f.). Se identifica "S.No."(Identificador del vehículo) como una columna sin valor analítico debido a que contiene el ID de cada fila. "Year"(Año de fabricación) y "Seats"(Cantidad de asientos) se identifican como variables numéricas discretas. Y las columnas "Kilometers_Driven"(Kilómetros recorridos) y "Price"(Precios en lakhs) como variables numéricas continuas.



	# S.No.	# Year	# Kilometers_Driven	# Seats	# Price
count	7253.0	7253.0	7253.0	7200.0	6019.0
mean	3626.0	2013.3653660554253	58699.063146284294	5.279722222222222	9.47946835022429
std	2093.905083808719	3.2544208117253053	84427.72058265151	0.8116596710740706	11.1879171124555
min	0.0	1996.0	171.0	0.0	0.44
25%	1813.0	2011.0	34000.0	5.0	3.5
50%	3626.0	2014.0	53416.0	5.0	5.64
75%	5439.0	2016.0	73000.0	5.0	9.95
max	7252.0	2019.0	6500000.0	10.0	160.0

Distribución de datos de tipo número

"Year"(Año de fabricación): La distribución está sesgada hacia la izquierda, conteniendo la mayoría de los valores en la derecha. Esto significa que la mayoría de los vehículos son relativamente nuevos.

"Kilometers_Driven"(Kilómetros recorridos): Esta gráfica está completamente sesgada hacia la derecha conteniendo la gran mayoría de valores en la izquierda. Además, observando los datos estadísticos de esta columna podemos ver qué el valor máximo está en `650.000` y el 75% en `73.000`. Esto puede suponer una presencia en outliers muy notoria.

"Seats": La gráfica muestra que la gran mayoría de vehículos tienen 5 o 7 asientos.

"Price": Con un sesgo hacia la derecha, conteniendo todos los valores en la izquierda se puede suponer que la gran mayoría de valores tienen un número bajo. Observando los datos estadísticos de esta columna se puede ver que el valor máximo está en `160`y el 75% en `9.95`, pudiendo suponer la existencia de outliers.

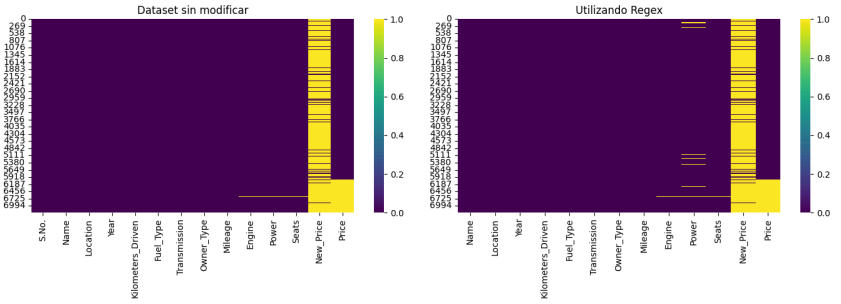
Limpieza del dataset

Valores nulos

Primero se utilizará una “expresión regular” (Cano, 2022) para poder convertir cualquier valor en texto que contenga la palabra null en un valor nulo de verdad. Expresión en regex: (?i).*null.* (Dib, s. f.). Esta expresión, permite encontrar palabras con ese patrón. De esta forma se puede encontrar la palabra null y convertirla en un valor nulo de verdad.

Dataset sin modificar:		Utilizando regex:	
Name	0	Name	0
Location	0	Location	0
Year	0	Year	0
Kilometers_Driven	0	Kilometers_Driven	0
Fuel_Type	0	Fuel_Type	0
Transmission	0	Transmission	0
Owner_Type	0	Owner_Type	0
Mileage	2	Mileage	2
Engine	46	Engine	46
Power	46	Power	175
Seats	53	Seats	53
New_Price	6247	New_Price	6247
Price	1234	Price	1234

Como se puede apreciar después de utilizar regex se ha podido identificar ciertos valores nulos en la columna “Power”.



Duplicados

Una vez convertidos los valores nulos se mira si hay valores duplicados. Se encuentra 1 línea duplicada que se eliminara.

Columnas Price

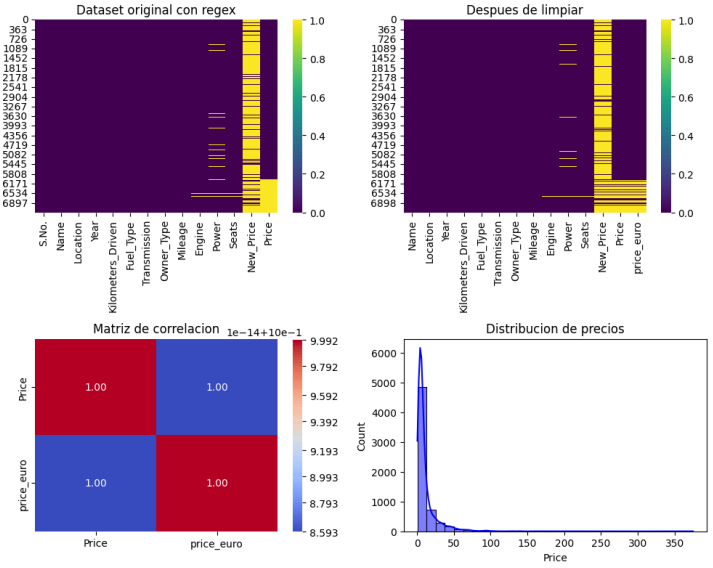
Después de ver el mapa de calor se ha identificado que la gran mayoría de valores nulos vienen de la columna “New_Price” y la columna “Price” por lo tanto serán las primeras columnas que se van a analizar y limpiar.

Se puede suponer que la columna “New_Price” contiene tantos nulos porque no se le ha dado un nuevo precio a la gran mayoría de vehículos, por lo tanto, se procedera a mover los valores de la columna “New_Price” a la columna “Price” sobrescribiendo solamente aquellos valores que tienen valor en “New_Price”. Pero primero hay que investigar qué tipos de valores hay en la columna “New_Price”. Se parte de la base de que los valores están formateados de la siguiente manera: “2 lakh“, con lo que se intuye que hay un número y un sufijo por lo que se crea una función que cuente la cantidad de sufijos y tipos de sufijos. Una vez se hace uso de esta función tenemos el siguiente resultado: 986 valores con sufijo “LAKH” y 20 valores con sufijo “CR”.

Para poder entender lo que se hará a continuación hay que investigar sobre el sistema numérico indio.

"La numeración india se utiliza para expresar números grandes. Se basa en agrupar dos posiciones decimales, tras agrupar las primeras tres posiciones decimales. Los términos lakh o 1.00.000 (cien mil, escrito como 100 000 en español) y crore o 1.00.00.000 (diez millones, escrito como 10 000 000 en español) son los términos más utilizados en el inglés indio para expresar números grandes en el sistema." (colaboradores de Wikipedia, 2024)

En resumen, se convertirá la numeración india en euros para que sea más entendible. Para hacer la conversión más realista se utilizara una página web que se dedica a las conversiones de moneda y contiene la conversión de 1 euro a 97.83 rupias indias (INR)(Xe, s. f.).



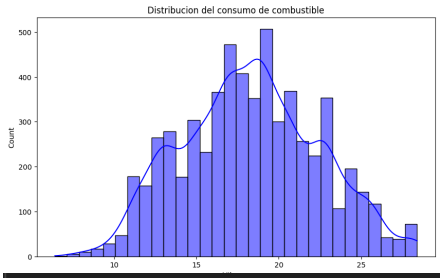
Se agruparán los valores CR y se convertirán en lakh multiplicando por 100. Después de convertir toda la columna "New_Price" con valores lakh, se creará una nueva columna "price_euro" convirtiendo los valores lakh a rupias indias y de rupias indias a euros. La conversión será de la siguiente forma: ((lakh * 100000) / 97.83). Una vez hecha la conversión se puede comprobar el mapa de calor de los valores nulos con las nuevas modificaciones. Al mover los valores de la columna "New_Price" a "Price" se ha reducido la cantidad de valores nulos en la columna "Price" y además se ha "clonado" en la columna "price_euro" para poder interpretar mejor los precios. También se puede ver la "relación entre las columnas 'Price' y 'price_euro' en la matriz de correlación, el cual teniendo un 1.0 se consideraría que hay una gran relación." (Wagavkar, 2024). Esto significa que son idénticas. Después de todo este proceso se elimina la columna "New_Price" por qué ya no es necesaria y se eliminaran los valores nulos de todas las columnas por falta de información.

Combustible

A continuación, se dará contexto a la columna "Fuel_Type" y "Mileage". Utilizando la función para obtener los diferentes sufijos se consigue el siguiente resultado; `'CNG': 56, 'Diesel': 3248, 'Petrol': 2740, 'LPG': 10` tal y como se ha visto en las gráficas de la inspección inicial los valores Diesel y Petrol son los más

utilizados entre todos los vehículos. En la columna “Mileage” se ha identificado que para los combustibles se utilizan diferentes métodos de conversión, para CNG y LPG se utiliza `km/kg`, para Diesel y Petrol se utiliza `kmpl`. Debido a que CNG y LPG son la minoría se convertirán los `km/kg` a `kmpl` para poder tener toda la columna con un mismo método.

Km/kg a kmpl

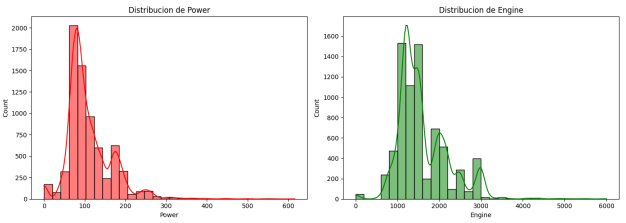


# Mileage	
count	6054.0
mean	18.210926660059467
std	4.30062851229516
min	0.0
25%	15.26
50%	18.2
75%	21.1
max	28.4

Se sabe que el “Gas natural comprimido (CNG) se mide en kilos. En general, se puede hacer el mismo kilometraje con 1kg que con 1.7 litros de gasolina”(*Fuel Distance*, s. f.). Puesto que 1kg equivaldría a 1.7 litros se convertirá de la siguiente manera: Dividiendo el valor en km/kg por 1.7 o multiplicándose por 0.588 (1/1.7 = 0.588) de esta forma se consigue una aproximación en kmpl. Y de forma similar “1kg de gas licuado del petróleo (LPG) equivaldría aproximadamente a 1.8 litros” (*Convert Kg To Liters Of LPG*, s. f.) Pudiendo dividir los km/kg por 1.8 o multiplicándose por 0.55 (1/1.8=0.55...) para obtener una aproximación en kmpl.

Cómo se modifican los valores en la columna “Mileage”, también se quitarán los sufijos, pudiendo así convertir esta columna a tipo float. Una vez modificados los valores en la columna “Mileage” y se ha podido convertir en float, se pueden ver las estadísticas descriptivas y observar que el valor mínimo es un 0 el cual supone un valor nulo en cuanto a kilometraje. Debido a que no se puede recuperar el valor de ninguna manera se eliminaran los valores 0 de la columna “Mileage”, eliminando un total de 28 filas.

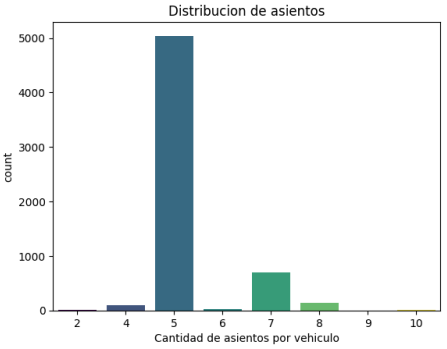
Capacidad y potencia del motor



En estas dos columnas solo se ha identificado un sufijo por cada columna por lo que se eliminaran los sufijos de cada columna, convirtiendo la columna “Engine” a número entero y la columna “Power” a float. Después de estos

cambios se puede generar un histograma para ver la distribución de ambos pudiendo identificar una posible cantidad de outliers. Además, viendo las estadísticas descriptivas se puede ver que el 75% de “Power” es `138.1` y el máximo es `616`, al igual con “Engine" el 75% está en `1984` y el máximo en `5998`. Al estar trabajando con vehículos todos estos outliers pueden significar una minoría en vehículos muy potentes.

	# Power	# Engine
count	6026.0	6026.0
mean	113.19895950879521	1621.415366744109
std	54.10710306216984	599.181000000279
min	34.2	624.0
25%	75.0	1198.0
50%	94.0	1495.0
75%	138.1	1984.0
max	616.0	5998.0

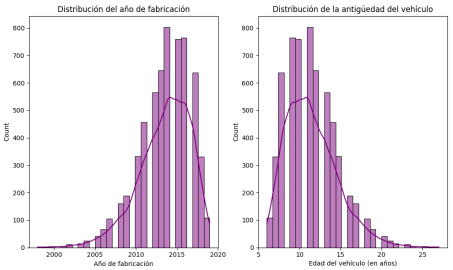


Asientos

Únicamente se cambiará el tipo de dato de float a integer ya que no hay decimales en asientos.

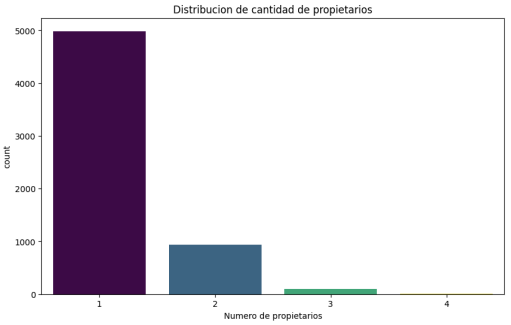
Edad del vehículo

La columna “Year” proporciona el año de fabricación, se convertirá este año de fabricación en la edad del vehículo pudiendo filtrar por la edad del vehículo y hacer que esta columna sea más interpretable.



Cantidad de propietarios por vehículo

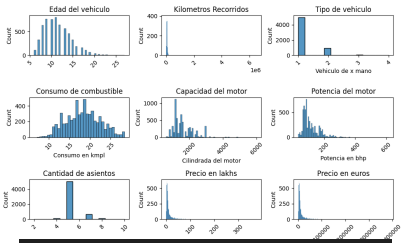
La columna “Owner_Type” proporciona la cantidad de propietarios que han pasado por cada vehículo. Con valores “First, Second, Thrid, Fourth & Above”, para poder interpretarlo mejor se transformaran estos a su correspondencia numérica, y puesto que no hay más información sobre “Fourth & Above” no se puede saber si el vehículo ha pasado por 4 o 100 propietarios por lo que se dejara el valor en 4.

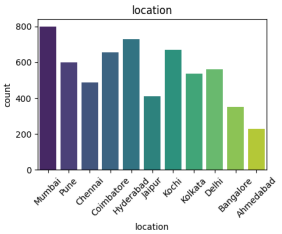


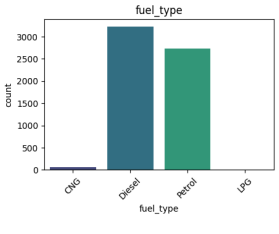
Conclusión de la exploración de datos

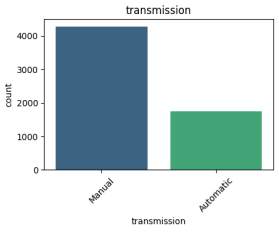
Finalmente se renombran las columnas para una mejor comprensión. Después de toda la limpieza hay 4 columnas de tipo objeto y 11 de tipo número. Gracias a este

proceso de limpieza y análisis inicial se han comprendido los datos y se podrá afrontar el pre-procesamiento de datos con más conocimiento y facilidad.







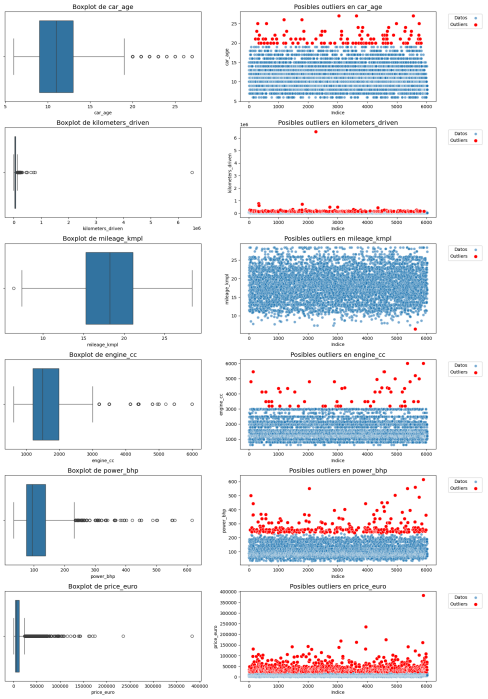



```
Data columns (total 13 columns):
 #   Column             Non-Null Count  Dtype
---  ------             --------------  -----
 0   name               6026 non-null   object
 1   location           6026 non-null   object
 2   car_age            6026 non-null   int64
 3   kilometers_driven  6026 non-null   int64
 4   fuel_type          6026 non-null   object
 5   transmission       6026 non-null   object
 6   owner_number       6026 non-null   int64
 7   mileage_kmpl       6026 non-null   float64
 8   engine_cc          6026 non-null   int64
 9   power_bhp          6026 non-null   float64
 10  seats              6026 non-null   int64
 11  price_lakh         6026 non-null   float64
 12  price_euro         6026 non-null   float64
```

Preprocesamiento de datos

Análisis y tratamiento de outliers

A continuación, se hará uso de un gráfico “boxplot para mostrar la distribución de datos cuantitativos para facilitar las comparaciones entre variables” (*Seaborn.Boxplot — Seaborn 0.13.2 Documentation*, s. f.). Esto permite visualizar aquellos datos que no están dentro de lo usual dentro del dataset. Y para ayudar a interpretarlo también se utilizará un gráfico “scatterplot que permite mostrar diferentes subconjuntos de datos utilizando parámetros de tono, tamaño y estilo” (*Seaborn.Scatterplot — Seaborn 0.13.2 Documentation*, s. f.). Para ambos se utilizará el “IQR (Rango intercuartílico), es un método para etiquetar valores atípicos” (*Oracle® Fusion Cloud EPM Trabajo Con Planning*, s. f.)



Según los gráficos, se puede observar ver que la gran mayoría de variables contienen una cantidad notable de posibles outliers. Pero que no estén dentro de la normalidad de los datos no significa que haya que eliminarlos, puesto que se está trabajando con vehículos con diferentes categorías y especificaciones, eliminarlos no sería la mejor opción, ya que el objetivo es poder alquilar o vender todos los vehículos. Lo que se puede hacer es etiquetarlos, dando una etiqueta a aquellos vehículos que sean más antiguos, tengan gran cantidad

de kilómetros recorridos, contengan un gran motor, un motor muy potente o que sea muy caro. Estas etiquetas permiten poder identificarlos y poder proporcionar a los usuarios con esta información.

Machine Learning

Modelo de recomendación de vehículos

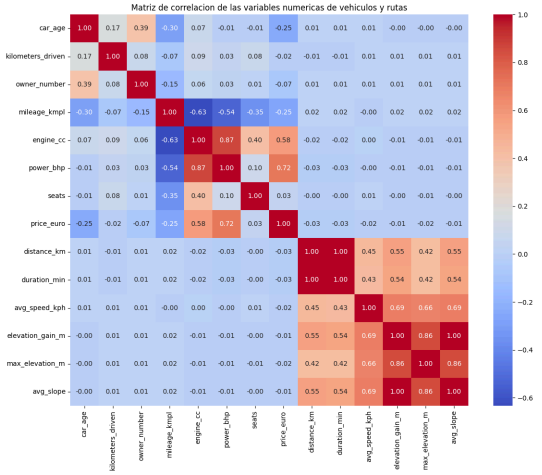
Una vez los datos han sido limpiados hay que investigar qué modelo se adapta mejor a esta situación. El objetivo principal es dar al usuario una lista de vehículos basados en sus preferencias y recomendar en base a la ruta seleccionada. Puesto que se quiere recomendar, se pueden utilizar algoritmos de filtrado colaborativo. Existen dos tipos de filtrado colaborativo principales, filtrado colaborativo y basado en contenido, “el filtrado colaborativo es un método que recomienda artículos a usuarios en función de otros usuarios con preferencias y comportamientos similares. En cambio el filtrado basado en contenido recomienda artículos exclusivamente en función de las características del perfil del artículo.”(Murel & Kavlakoglu, s. f.)

El problema del cold-start

No hay datos de usuarios que recomienden estos vehículos o usuarios que hayan realizado una ruta con un vehículo y puesto una reseña. Por lo que hay un problema de inicio frío(cold-start) esto significa que no hay suficientes datos historicos para poder utilizar un modelo de filtrado colaborativo, de forma que el modelo que más puede favorecer a esta situación podría ser un sistema híbrido de recomendación basado en el contenido y en conocimiento. “Esto nos permite recomendar elementos sin necesidad de un historial previo, siguiendo unas reglas y pautas sobre qué es lo que se debería de recomendar o dando un ejemplo de recomendación” (Wu, 2022).

Construcción del modelo

Filtrado basado en preferencias:

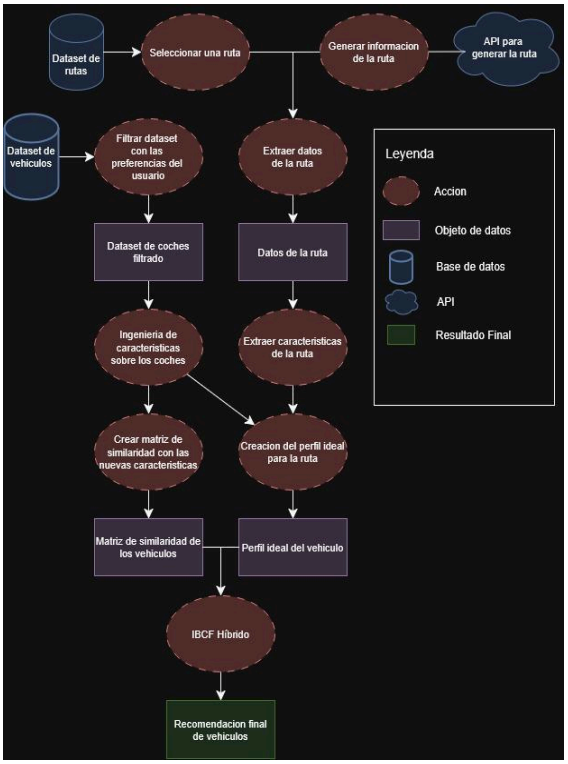


Se filtran y descartan los vehículos que no cumplen las preferencias del usuario, como el precio máximo, la edad máxima del vehículo, el tipo de combustible o el tipo de transmisión.

Ingeniería de variables:

Se consta con variables de vehículos y rutas los cuales no se pueden juntar y utilizar ya que están a escalas diferentes y no tienen relación directa entre sí. Por lo que se transformaran las variables de los vehículos creando nuevas variables más representativas para ayudar en la comparación de los vehículos utilizando la similitud del coseno consiguiendo que los datos tengan más sentido y los resultados sean más útiles.

Perfil ideal del vehículo:



Con los datos de la ruta se crea un perfil a partir de unos pesos y variables como la distancia, la elevación o la inclinación media, este perfil especifica, por ejemplo, una mayor eficiencia de combustible si la distancia es larga o más potencia de motor si el desnivel es muy elevado. Después se compara el perfil ideal con todos los vehículos utilizando la similitud del coseno dando una puntuación por coincidencia..

Modelo de recomendación híbrido:

Posteriormente se aplica una técnica inspirada en el filtrado colaborativo basado en ítems (Item Based collaborative filtering), utilizando la similitud

entre los vehículos para reforzar las recomendaciones. Acabando con una puntuación ponderada de ambas aproximaciones y devolviendo un ranking de vehículos para que el usuario seleccione entre ellos.

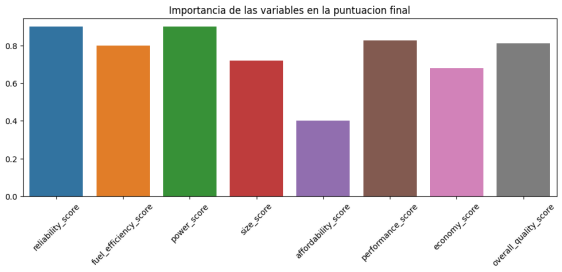
Ejemplo:

Datos de la ruta: **Origen**: Barcelona, **Destino**: Madrid, **Distancia**: 626 km, **Duración**: 382 Minutos, **Elevación**: 2582 metros, **Máxima elevación**: 1164 metros, **Media de inclinación**: 51 grados.

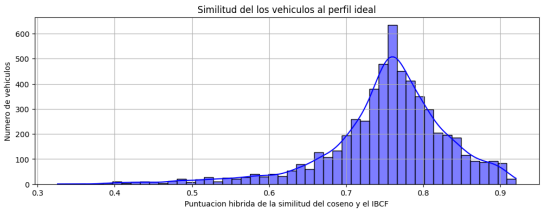
Preferencias del usuario: **Precio máximo**: 50.000, **Edad máxima del vehículo**: 20 años, **Combustible:** Diesel o gasolina, **Tipo de transmisión**: Manual o automático, **Top de vehículos para mostrar**: 10.

Después de utilizar el modelo de machine learning con la ruta y preferencias del usuario, obtenemos los siguientes gráficos:

Este gráfico de barras representa el peso que se le da a cada variable en cuanto a la puntuación de la similitud del coseno, pudiendo variar por el tipo de ruta.



Esta gráfica de tipo histograma representa los todos vehículos una vez finalizado el modelo de machine learning donde se le ha dado una puntuación que indica cuán recomendado es el vehículo para la ruta donde 0 es nada recomendado y 1 muy recomendado.



Y finalmente obtener la cantidad de vehículos especificados por el usuario y los vehículos recomendados por el modelo para que el usuario tenga una decisión final.

	name	location	car_age	kilometers_driven	fuel_type	transmission	owner_number	mileage_kmpl	engine_cc	power_bhp	seats	price_euro
1011	BMW 5 Series 2013-2017 525	Bangalore	12	58500	Diesel	Automatic	2	17.09	1995	218.0	5	28109.99
5704	Skoda Superb Style 1.8 TSI AT	Kochi	14	72734	Petrol	Automatic	2	14.67	1798	177.46	5	34099.97
2296	Skoda Superb Style 1.8 TSI AT	Mumbai	15	62004	Petrol	Automatic	2	14.67	1798	177.46	5	34099.97
1858	Jaguar XF 2.2 Litre Luxury	Mumbai	12	31400	Diesel	Automatic	1	16.36	2179	187.7	5	27343.35
4566	Mercedes-Benz M-Class ML 2	Mumbai	13	52000	Diesel	Automatic	1	15.26	2143	203.2	5	30614.33
4343	Jaguar XF Aero Sport Edition	Delhi	13	16000	Diesel	Automatic	1	16.36	2179	187.7	5	32709.8
4298	Jaguar XF 2.2 Litre Luxury	Pune	12	46000	Diesel	Automatic	2	16.36	2179	187.7	5	24532.35
5164	BMW 5 Series 2013-2017 520	Jaipur	12	40714	Diesel	Automatic	2	18.12	1995	190.0	5	25298.99
3703	BMW X3 xDrive20d	Bangalore	13	52000	Diesel	Automatic	1	16.09	1995	184.0	5	24532.35
825	Audi A6 2011-2015 2.0 TDI	Hyderabad	12	70181	Diesel	Automatic	1	17.68	1968	174.33	5	24522.13

Conclusión del modelo híbrido

El sistema híbrido aplicado permite tratar el problema cold-start debido a que no se dispone de datos históricos, además la solución utilizada no solo filtra los vehículos por las preferencias de los usuarios sino que los adapta según la ruta seleccionada. Además la creación de nuevas variables enriquecidas a partir de los datos originales y el perfil ideal basado en las características de la ruta han permitido crear unas comparaciones más significativas. Proporcionando recomendaciones más realistas y útiles para el usuario.

Conclusión Final

Esta prueba de concepto/proyecto ha requerido de una exploración de datos exhaustiva debido a que los datos originales tenían inconsistencias: datos mal formateados, datos faltantes, además de contener diferentes sistemas numéricos y métricos. Se ha conseguido obtener un dataset limpio, bien formateado y sin datos faltantes, adecuado para el procesamiento.

Posteriormente se ha pre-procesado analizando posibles outliers los cuales se han tratado con etiquetas ya que se está trabajando con vehículos de primera y segunda mano que pueden contener diferentes especificaciones.

Finalmente se ha creado un sistema de recomendación híbrido basándose en el contenido de los vehículos y el conocimiento de las rutas. Extrayendo y creando variables para poder crear un perfil ideal y poder comparar los vehículos para encontrar los que mejor se adapten. Este enfoque ha permitido ofrecer recomendaciones personalizadas con la ausencia de datos históricos superando el problema del cold start.

De todas formas en un caso real se utilizarían datos fiables y generados a base de los vehículos que la empresa tiene identificados. Aun así se haría una exploración de datos para identificar fallos, datos faltantes o mal formateados. Se guardarán en una base de datos como s3 bucket de amazon para acceder fácilmente e incluso se utilizaria una base de datos en memoria como redis para reducir la cantidad de queris hacia la base de datos, también se utilizaria incluso para reducir las llamadas a la API de google maps, además de investigar si sería rentable guardar las rutas

más comunes para evitar realizar llamadas a la API de google maps reduciendo el coste total. También se dispondrá de datos más específicos sobre los vehículos como puede ser la anchura y el largo del vehículo, el tamaño de las llantas o neumáticos, el tamaño de las puertas o del maletero. Pudiendo incluso utilizar un modelo de clustering para categorizar los vehículos sin necesidad de etiquetas. Crear un historial a medida que se van alquilando o comprando vehículos a base de rutas e intentar incorporar un sistema de recomendación colaborativo usuario a usuario para recomendar a base de reseñas.

Creo que esta prueba de concepto aunque sea un poco específica puesto que utiliza rutas como pieza para recomendar un vehículo, puede ser una base para poder utilizar de ejemplo en casos reales y conseguir completar objetivos más grandes.

ANEXOS

Webgrafía

Cars Dataset. (2024, 11 marzo). Kaggle. https://www.kaggle.com/datasets/ayushparwal2026/cars-dataset/data

seaborn.countplot — seaborn 0.13.2 documentation. (s. f.). https://seaborn.pydata.org/generated/seaborn.countplot.html

Habib, J. M. (2024b, noviembre 26). Understanding Categorical Columns in Data Analysis and Machine Learning. *Medium*. https://medium.com/@jaberi.mohamedhabib/understanding-categorical-columns-in-data-analysis-and-machine-learning-51538d5d632d

Dubey, A. (2025, 11 marzo). Introduction to Categorical, numerical, discrete and continuous variables. *Medium*. https://medium.com/@alokdubeyforu/introduction-to-categorical-numerical-discrete-and-continuous-variables-5974fc717ab8

Visualizing distributions of data — seaborn 0.13.2 documentation. (s. f.). https://seaborn.pydata.org/tutorial/distributions.html

Chen, J. (2025b, mayo 28). *What Is Skewness? Right-Skewed vs. Left-Skewed Distribution*. Investopedia. https://www.investopedia.com/terms/s/skewness.asp

Dib, F. (s. f.). *regex101: build, test, and debug regex*. Regex101. https://regex101.com/

Cano, I. R. (2022, 26 octubre). *¿Qué son las Expresiones regulares? (RegEx) - Viewnext.com*. Viewnext.com. https://www.viewnext.com/que-son-las-expresiones-regulares-regex/

colaboradores de Wikipedia. (2024, 1 diciembre). *Numeración india*. Wikipedia, la Enciclopedia Libre. https://es.wikipedia.org/wiki/Numeraci%C3%B3n_india

Xe. (s. f.). *1 EUR to INR - Euros to Indian Rupees Exchange Rate*. https://www.xe.com/currencyconverter/convert/?Amount=1&From=EUR&To=INR

Wagavkar, S. (2024, 20 noviembre). *Introduction to the Correlation Matrix*. Built In. https://builtin.com/data-science/correlation-matrix

Fuel distance. (s. f.). https://www.bigas.it/en/faq-en/292-faq-fuel-distance

Convert kg to liters of LPG. (s. f.). https://conversion.website.yandexcloud.net/convert-kg-to-liters-lpg.html

seaborn.boxplot — seaborn 0.13.2 documentation. (s. f.). https://seaborn.pydata.org/generated/seaborn.boxplot.html

seaborn.scatterplot — seaborn 0.13.2 documentation. (s. f.). https://seaborn.pydata.org/generated/seaborn.scatterplot.html

Oracle® Fusion Cloud EPM Trabajo con Planning. (s. f.). https://docs.oracle.com/cloud/help/es/pbcs_common/PFUSU/insights_metrics_IQR.htm#PFUSU-GUID-CF37CAEA-730B-4346-801E-64612719FF6B

Wu, J. (2022, 30 marzo). Knowledge-Based Recommender Systems: An Overview - Jackson Wu - Medium. *Medium*. https://medium.com/@jwu2/knowledge-based-recommender-systems-an-overview-536b63721dba

Murel, J., PhD, & Kavlakoglu, E. (s. f.). Collaborative filtering. *What is collaborative filtering?* https://www.ibm.com/think/topics/collaborative-filtering

Código

Link a la página de github: https://github.com/Daemonistaken/vehicle_recommender

1- Para poder replicar el repositorio primero tenemos que clonarlo con el siguiente comando `git clone https://github.com/Daemonistaken/vehicle_recommender.git `

2- Hay que crear el entorno virtual utilizando python o python3 utilizar el siguiente comando. `python -m venv venv` or `python3 -m venv venv`

3- Hay que instalar las librerías con `pip install -r requirements`

4- Ejecutar el archivo `data_cleaning.ipynb`

5- Añadir un archivo .env con la API de google maps en caso de utilizar la ruta personalizada dentro del archivo `data_pre-processing.ipynb`

La API key debe que tener acceso a las siguientes API:

- Places
- Directions
- Elevation

6- Modificar las configuraciones respetando las limitaciones en la primera celda del archivo `data_pre-processing.ipynb` y ejecutarlo

Información adicional:

Los datasets están en la carpeta “datasets” divididos en otras carpetas por vehículo y ruta, a excepción del dataset del ranking final de vehículos.

El archivo `data_cleaning.ipynb` contiene la exploración de datos con todos los gráficos mostrados en el documento.

El archivo `data_pre-processing.ipynb` contiene el pre-procesamiento de los datos y el modelo de machine learning.

El archivo `mapsAPI.PY` contiene el código para generar las rutas personalizadas.